

论文关联推荐引擎设计 - 实际落地版

Embedding + BM25 + 标签先验 + 关系表 + 地图快照 - 给 Codex 的后端/算法任务文档

边界: published-only; AI/模型 default-off; 推荐结果必须可解释。

核心结论: 当前项目没有 embeddings/relations/runs, 应先做 schema 与无模型基线, 再接本地 embedding。

版本: v3.2-adjusted | 生成日期: 2026-05-29

本文件是对“中英混合论文知识库关联分析、聚类与推荐最终方案”的工程落地修订版。它保留原方案的长期技术方向, 但把第一阶段调整为适配当前 FastAPI + SQLite + 轻量依赖的可运行实现。

0. 本版修订结论

最终判断: 原方案的 BGE-M3 / Reranker / HDBSCAN / Leiden / UMAP 是正确的长期方向, 但当前后端 pyproject 只有 FastAPI、Pydantic、webtypy, 且 /api/items/{id}/similar 只是同聚类/坐标邻近占位。因此第一阶段必须先做“无模型可运行推荐基线 + 数据表 + 后台任务记录”, 再逐步接入本地 embedding。

模块	原最终方案	当前项目实际	本版落地策略
主 embedding	BGE-M3 默认	当前无 item_embeddings, 后端无 sentence-transformers/hnswlib 依赖	R0/R1 不引入模型; R3 通过 optional extra 接 e5-small/BGE-M3
关键词检索	SQLite FTS5/BM25	当前 /api/map q 只 LIKE title/summary/tags_json	先加 knowledge_items_fts, 作为无模型召回
关系评分	dense + BM25 + tag + citation + reranker	当前 /similar 用 same cluster + coordinate distance	先写 item_relations, 用 tag + BM25 + cluster + coordinate 评分
聚类地图	UMAP + HDBSCAN + Leiden	当前 x/y 存在 knowledge_items, 无 map_snapshots	保留当前 x/y; map_snapshots 后置到 R4
Reranker/LLM	推荐增强与解释	当前 AI default-off	只做可选 provider; 默认模板解释
用户端展示	详情相似论文、地图高亮	当前详情已有 similarItems 列表	替换为 RelatedItemsPanel, 兼容 similar API

1. 当前后端与数据基线

1.1 已有能力

- FastAPI 入口是 backend/src/worker.py, 同时保留原 Aella papers 接口和新增知识库接口。
- 本地 SQLite 会自动创建 knowledge_bases、knowledge_items、tags、item_tags。
- GET /api/map 明确筛选 review_status = published 且 x/y 不为空, 这是推荐与地图必须继承的硬边界。
- GET /api/items/{item_id}/similar 当前基于同 cluster 或坐标距离返回 published 条目, 可作为兼容 fallback。
- 上传创建 pending_review, 管理员 publish 后才写 published_at 并进入地图。
- tags/item_tags 已经支持结构化标签树、分组、层级、source/confidence, 可直接作为推荐算法的人工先验。

1.2 目前缺口

缺口	影响	最小补法
没有 canonical_text	embedding/BM25 输入不稳定	新增 paper_text_service.py, 从 title/summary/tags/author/year/content_preview 生成文本
没有 item_embeddings	无法做向量相似	先建表但不启用模型; R3 再写入
没有 item_relations	相似关系无法持久、无法解释	先用无模型基线写入 relation rows
没有 recommendation_runs	后台无法知道任务何时生成、是否失败	新增 runs 表与 admin APIs
没有 FTS5	专业术语和缩写检索弱	新增 SQLite FTS5 表并维护索引
worker.py 过大	继续推算法会难维护	新增 backend/src/recommendations/* 服务模块
没有 map_snapshots	地图重建不可回滚	R4 加入, 非第一步

2. 推荐引擎分阶段目标

图 3-1 数据库设计 - 实际落地版

R0 审计	R1 基线	R2 关系表	R3 向量	R4 地图重建	R5 精排/解释
默认可运行是	是	是	否	否	否
需要新增依赖	无	无	可选	可选	可选
写入用户端否	相似占位	related API	相似增强	map snapshot	推荐理由
后台管理文档	任务按钮	run 记录	模型配置	重建发布	评估看板

阶段	目标	模型依赖	对用户端影响
R0 审计与文档	确认当前字段、API、published 过滤、标签体系	无	无 UI 变化
R1 无模型基线	canonical_text + FTSS + tag/cluster/坐标评分	无	/similar 可更稳定, 但仍 fallback
R2 关系持久化	item_relations + recommendation_runs + /related API	无	详情面板可显示分数、关系类型、证据
R3 本地 embedding	optional embedding provider, 写 item_embeddings	可选: e5-small/BGE-M3	相似度质量提升
R4 地图与聚类快照	map_snapshots, item_clusters, 可选 UMAP/HDBSCAN	可选: umap-learn/hdbscan	地图坐标可重建和回滚
R5 Reranker/解释	reranker + evidence_json -> reason	可选: Qwen/BGE reranker, 小 LLM 可关	推荐理由更好

3. 数据库设计 - 最小可落地版

3.1 新增表

表	核心字段	第一阶段是否启用	说明
recommendation_runs	id, knowledge_base_id, mode, status, item_count, relation_count, started_at, finished_at, error_message, config_json	是	所有重建任务必须可追踪
item_relations	id, source_item_id, target_item_id, relation_type, score, evidence_json, run_id, created_at	是	先存无模型推荐, 后续向量/精排共用
knowledge_items_fts	item_id, title, summary, tags, content_preview, canonical_text	是	SQLite FTSS 虚表或同步表
item_embeddings	id, item_id, model_name, vector_blob, dimension, text_hash, created_at	建表可先不用	R3 启用
item_clusters	item_id, cluster_id, algorithm, probability, run_id	后置	R4 启用
map_snapshots	id, knowledge_base_id, algorithm, params_json, status, created_at, published_at	后置	R4 启用
map_points	snapshot_id, item_id, x, y, cluster_id	后置	从 knowledge_items.x/y 迁移

3.2 SQL 草案

```
CREATE TABLE IF NOT EXISTS recommendation_runs (  
  id TEXT PRIMARY KEY,
```

```

knowledge_base_id TEXT NOT NULL,
mode TEXT NOT NULL DEFAULT 'baseline',
status TEXT NOT NULL,
item_count INTEGER DEFAULT 0,
relation_count INTEGER DEFAULT 0,
config_json TEXT NOT NULL DEFAULT '{}',
started_at TEXT NOT NULL,
finished_at TEXT,
error_message TEXT
);

CREATE TABLE IF NOT EXISTS item_relations (
  id TEXT PRIMARY KEY,
  source_item_id TEXT NOT NULL,
  target_item_id TEXT NOT NULL,
  relation_type TEXT NOT NULL,
  score REAL NOT NULL,
  evidence_json TEXT NOT NULL DEFAULT '{}',
  run_id TEXT,
  created_at TEXT NOT NULL,
  UNIQUE(source_item_id, target_item_id, relation_type, run_id)
);

-- ■■: FTS5 ■■■■■■■■■■■■
CREATE VIRTUAL TABLE IF NOT EXISTS knowledge_items_fts USING fts5(
  item_id UNINDEXED,
  title,
  summary,
  tags,
  content_preview,
  canonical_text
);

```

4. 服务模块设计

模块	建议路径	职责	默认行为
文本规范化	backend/src/recommendations/paper_text_service.py	build_canonical_text(item): title + summary + tags + author/year/source + content_preview	无外部依赖
FTS/BM25	backend/src/recommendations/lexical_search_service.py	刷新 FTS5, 关键词召回, rank 归一化	无外部依赖
关系评分	backend/src/recommendations/relation_score_service.py	tag overlap + bm25 rank + same cluster + coordinate proximity -> score/evidence	无外部依赖
推荐任务	backend/src/recommendations/recommendation_job_service.py	rebuild_baseline_relations, 写 run 和 relation	同步执行即可, 后续再队列
Embedding	backend/src/recommendations/embedding_service.py	provider 接口: NoopProvider, SentenceTransformersProvider	默认 Noop, 不影响启动
向量索引	backend/src/recommendations/vector_index_service.py	R3 后使用 numpy/hnswlib 或简单 cosine	默认关闭
地图布局	backend/src/recommendations/map_layout_service.py	R4 后 UMAP/HDBSCAN/Leiden 与 map snapshot	默认不启用

5. 基线推荐算法

R1/R2 的目的不是打败 embedding, 而是在没有模型、没有 GPU、没有外部服务时先让系统拥有“可解释、可持久、可审核”的相关论文能力。

5.1 候选召回

```

C(item) =
  same_knowledge_base_published_items
  filtered by item_id != source_id
  top by:
    1. same structured tag group overlap
    2. FTS5 BM25 against canonical_text
    3. same cluster_id
    4. nearest x/y coordinate

```

candidates <= 80, relations <= 20.

5.2 基线分数

信号	计算	权重	证据字段
S_tag	按 tag_group 加权 Jaccard; research_topic > academic_domain > content_type	0.38	shared_tag_ids, shared_tag_names
S_bm25	FTS5 rank 或查询词重叠, rank-based 归一化	0.24	matched_terms, bm25_rank
S_cluster	cluster_id 相同为 1, cluster_label 相似为 0.5	0.16	same_cluster
S_coord	1 / (1 + normalized_distance), 只作弱信号	0.12	coordinate_distance
S_meta	年份接近、作者/来源相同弱加分	0.06	shared_author, year_delta
Admin	后续人工强相关/负反馈覆盖	0.04 或覆盖	admin_feedback

baseline_score =
0.38*S_tag + 0.24*S_bm25 + 0.16*S_cluster +
0.12*S_coord + 0.06*S_meta + 0.04*S_admin

score >= 0.52
score >= 0.62
score >= 0.78

6. API 设计

接口	方法	端	职责	实现阶段
/api/admin/recommendations/rebuild	POST	后台	触发 baseline 或 embedding 推荐重建; 返回 run_id	R2
/api/admin/recommendations/runs	GET	后台	查看历史任务、状态、耗时、错误	R2
/api/admin/recommendations/runs/{id}	GET	后台	查看单次 run 详情和统计	R2
/api/items/{id}/related	GET	用户端	返回 item_relations 中的相关条目、score、relation_type、reason	R2
/api/items/{id}/similar	GET	用户端	保留兼容; 有 relation 时优先用 semantic/same_topic, 无则 fallback	R2 改造
/api/admin/map-snapshots/rebuild	POST	后台	触发地图快照重建	R4
/api/map?snapshot_id=latest	GET	用户端	未来读取快照坐标; 当前仍用 knowledge_items.x/y	R4

7. 前端接入设计

位置	当前状态	调整
FloatingDetailPanel	展示 similarItems, 没有分数/关系类型/证据	抽 RelatedItemsPanel, 支持 relatedItems: title, score, relation_type, reason, shared_tags
SelectedDetailStrip	移动端 sticky 详情也显示 similarItems	共用 RelatedItemsPanel 的 compact 模式
KnowledgeMapCanvas	只支持 selectedPointId/activeAxisNodeId	新增 highlightedPointIds/dimmedPointIds/relatedPointIds 可选 props
DataCard	列表展示节点摘要	显示“已有关联推荐”状态可后置
Admin Console	/admin/items 与 /admin/settings 仍部分占位, /admin/tags 已有页面	新增 /admin/recommendations 或先复用 /admin/items 下的任务区

8. Codex 可执行任务清单 - 后端/算法版

执行原则: 先无模型基线, 再模型增强。每个任务必须保证无 AI key、无 GPU、无额外模型下载时项目仍能启动。所有用户端推荐只读取 published 条目。

任务	目标	修改范围	具体要求	验收标准
R0	只读推荐审计	README、worker.py、models.py、types/knowledge.ts、UserMapPage、现有/similar	docs/v3-recommendation-audit.md	说明现有表、过滤、similar 逻辑、缺失表; 无代码 diff
R1	新增推荐数据模型与 schema	models.py、worker.py schema 初始化或独立 migration helper	recommendation_runs, item_relations, item_embeddings 表; Pydantic 模型	py_compile 通过; 旧 API 不变
R2	canonical_text 服务	backend/src/recommendations/paper_text_service.py	从 KnowledgeItem row 生成稳定文本与 text_hash	给 demo item 输出稳定 canonical_text
R3	FTS5/BM25 基线索引	lexical_search_service.py, schema init	创建/刷新 knowledge_items_fts, 只索引 published	pending_review 不进入 FTS
R4	基线关系评分服务	relation_score_service.py	tag + bm25 + cluster + coord + meta -> score/evidence_json	同一 item 返回 Top 20 可解释候选
R5	推荐重建任务 API	recommendation_job_service.py, worker routes	POST rebuild, GET runs, 写 recommendation_runs/item_relations	失败有 error_message, 成功有 relation_count
R6	/api/items/{id}/related	worker route, models.py	读取 item_relations 并返回 item + score + relation_type + evidence/reason	只返回 published; 没有 relation 返回空数组
R7	兼容 /similar	现有 similar route	如果有 item_relations, 优先返回 relation; 否则 fallback 到同 cluster/坐标	前端无需马上改也可获益
R8	前端 RelatedItemsPanel	UserMapPage/DetailPanel/userKnowledge Api/types	显示分数、关系类型、共享标签、理由; 可高亮地图节点	无 relation 时仍显示旧 similar
R9	后台推荐任务页最小版	Admin route/page/API adapter	列表展示 runs, 按钮触发 baseline rebuild	不接模型配置; 不做队列
R10	Embedding provider 抽象	embedding_service.py + optional dependency 文档	NoopProvider 默认; SentenceTransformersProvider 可选	未安装模型依赖时不报错
R11	map_snapshots 设计文档	docs/v3-map-snapshot-plan.md	只写设计: map_points, item_clusters, rebuild rules	不改用户地图 API
R12	质量验收脚本	backend/src/recommendations/evaluate_baseline.py	抽样输出每篇 Top relations 和证据	不要求人工标注系统

9. 长期算法路线保留

9.1 什么时候接 BGE-M3

- 当 R1-R7 已经稳定, 且数据量超过几百到几千篇, baseline 的 Top 10 质量不能满足时再接 embedding。
- 本地 CPU 演示优先使用 multilingual-e5-small 或 Qwen3-Embedding-0.6B 级别模型; BGE-M3 作为实验室 GPU 默认目标。
- embedding 模型只能在后台任务中运行, 不允许前端点击节点时同步计算。

9.2 UMAP/HDBSCAN/Leiden 的位置

- 当前地图坐标直接存在 knowledge_items.x/y, 不要马上迁移。
- 当 item_embeddings 和 item_relations 稳定后, 再新增 map_snapshots/map_points, 支持 UMAP 坐标重建和回滚。
- HDBSCAN 可作为语义密度簇, Leiden 可作为关系社区, 但二者输出都必须保留 run_id 和算法参数。
- 新增论文发布后不立即全量重建地图; 先通过最近邻或临时坐标进入地图, 周期性全量重建后发布新版快照。

10. 风险与避免事项

风险	表现	规避
一次性引入重模型	本地启动失败、CI 失败、用户无法演示	所有模型依赖 optional, 默认 Noop/Baseline
未发布条目进入推荐	pending_review 被用户看到	所有查询 where review_status = published; 测试覆盖

风险	表现	规避
worker.py 继续膨胀	算法逻辑难维护	新建 recommendations 服务目录, worker 只做路由
推荐不可解释	用户只看到相似分数	必须保存 evidence_json 和模板 reason
地图漂移过大	用户找不到熟悉位置	map snapshot 后再处理, 且需要管理员发布新版
强行做 Leiden/HDBSCAN	第一版依赖复杂, 调试困难	先 tag/FTS/cluster/coord baseline

11. 验收清单

验收项	必须满足
默认启动	未安装 sentence-transformers、hnswlib、umap、hdbscan 时后端仍可启动
数据边界	recommendation rebuild、FTS、related API 均只处理 published
推荐结果	任意 published item 可返回 0-N 个 related items, 每条含 score、relation_type、evidence_json 或 reason
兼容性	旧 /api/items/{id}/similar 不破坏; 前端详情仍可显示相似条目
后台任务	管理员可看到 run status、item_count、relation_count、error_message
质量	抽样 20 篇时, 推荐证据中至少出现共享标签、BM25 命中、同簇或坐标邻近之一
工程	backend python compile 通过; frontend tsc/build 通过

12. 输入依据

- 当前仓库 README、docs/project-structure-analysis.md、docs/v3-role-split-architecture.md、docs/v3-tag-schema-design.md。
- 当前后端 worker.py: schema、/api/map、/api/items/{id}/similar、上传审核发布、tag APIs。
- 当前前端 UserMapPage.tsx、KnowledgeMapCanvas.tsx、types/knowledge.ts、types/tags.ts、knowledgeApi.ts。
- 原 PDF: final_paper_knowledge_recommendation_scheme.pdf - published-only、BGE-M3、BM25、Reranker、HDBSCAN/Leiden/UMAP。
- 原 PDF: Knowledge_Galaxy_Codex_Design_Document.pdf - 2D 知识星图与右侧详情面板设计。